Guía de Desarrollo de Aplicaciones de Big Data

Mg. Ing. Yury Tello Canchapoma

La arquitectura de Big Data no se define por la cantidad de datos acumulados, sino por la precisión con la que la tecnología responde a la latencia y complejidad de cada escenario de negocio.

Guía Esencial: Desarrollo de Aplicaciones de Big Data

Fundamentos y Ecosistema Tecnológico

El Modelo de las 4V del Big Data

Pilares del Procesamiento y Almacenamiento

El Origen: Las Tres Tesis de Google

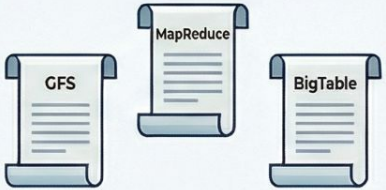

Tecnología basada en los artículos originales sobre OFS, MapReduce y BigTable de 2004.

Soluciones y Escenarios de Aplicación

Procesamiento Offline vs. Tiempo Real

Data Warehouse Convergente

Casos de Uso por Industria

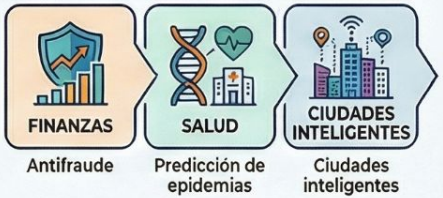

Comparativa de herramientas según la etapa del flujo de datos

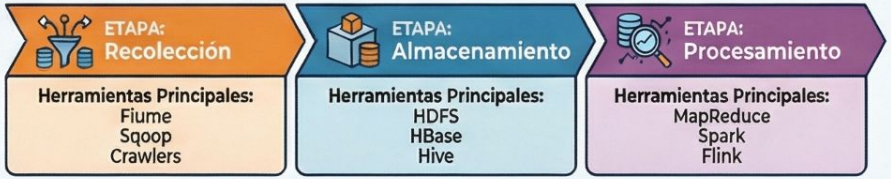

NotebookLM

Agenda

1. **Introducción y Contexto:** La era del Big Data y su evolución.
2. **Tecnologías Dominantes:** Recolección, almacenamiento, procesamiento y análisis.
3. **Soluciones Basadas en Escenarios:**
    - Procesamiento por lotes (Offline Batch).
    - Búsqueda en tiempo real (Real-time Retrieval).
    - Procesamiento de flujos (Stream Processing).
    - Data Warehouse Convergente (DWS).
4. **Guía de Desarrollo de Aplicaciones:** Habilidades, procesos y capas de datos.
5. **Conclusiones.**

Introducción
Las Tres Olas de la Información

- **Primera Ola (1980):** Centrada en el procesamiento de información (PCs).
- **Segunda Ola (1995):** Centrada en la transmisión de información (Internet).
- **Tercera Ola (2010):** Centrada en la explosión de información (IoT, Cloud Computing, Big Data).
- **Factores Impulsores:** Mejora en el rendimiento de CPU, mayor capacidad de almacenamiento y aumento del ancho de banda de red.

Definición de Big Data (Las 4V)

- **Volumen:** Conjuntos de datos masivos que superan la capacidad del software tradicional.
- **Variedad:** Diversidad de tipos de datos (estructurados, semiestructurados y no estructurados).
- **Velocidad:** Necesidad de procesamiento y respuesta rápida.
- **Valor:** Baja densidad de valor inicial; se requiere análisis para extraer conocimiento útil.

Origen y Evolución Tecnológica

- **Los Tres Pilares de Google (2003-2004):**
  - **GFS:** Sistema de archivos distribuido.
  - **MapReduce:** Framework de computación distribuida.
  - **BigTable:** Sistema de base de datos distribuida.
- **Hitos Clave:**
  - **2006:** Nacimiento de Hadoop.
  - **2008:** Facebook contribuye con Hive.
  - **2014:** Spark y Flink se convierten en proyectos top-level de Apache.

Tecnologías Dominantes
Recolección y Almacenamiento

- **Recolección de Datos:**
  - **Flume:** Recolección de logs en streaming.
  - **Sqoop:** Transferencia de datos entre bases de datos relacionales y Hadoop.
  - **Crawlers:** Rastreo de datos masivos de la web.
- **Almacenamiento y Gestión:**
  - **HDFS:** Almacenamiento distribuido escalable.
  - **HBase:** Base de datos NoSQL para acceso aleatorio rápido.
  - **Hive:** Gestión de datos estructurados sobre Hadoop (Data Warehouse).

Tecnologías Dominantes Procesamiento y Análisis

- **Procesamiento:**
  - **MapReduce:** Ideal para procesamiento por lotes offline.
  - **Spark:** Procesamiento en memoria más rápido que MapReduce.
  - **Flink:** Procesamiento de flujos en tiempo real con baja latencia.
- **Análisis:**
  - Uso de motores de consulta como **Hive SQL** o **SparkSQL** para transformar datos crudos en indicadores de negocio.

Solución 1 - Procesamiento por Lotes (Offline Batch)

- **Concepto:** Almacenamiento y análisis de datos históricos masivos que no requieren respuesta inmediata.
- **Escenario:** Generación de reportes diarios, análisis de tendencias a largo plazo.
- **Flujo de Datos:** Datos fuente → Ingesta (Loader/Sqoop) → Almacenamiento (HDFS) → Procesamiento (Hive/Spark) → Resultados (MySQL/Visualización).

Solución 2 - Búsqueda en Tiempo Real (Real-time Retrieval)

- **Requisitos Core:**
  - Búsqueda por clave primaria: Respuesta en **<1 segundo**.
  - Búsqueda por otros campos: Respuesta en **<3 segundos**.
  - Alta concurrencia: Más de 100 consultas simultáneas.
- **Componentes Principales:**
  - **HBase:** Para consultas simples y rápidas.
  - **Elasticsearch:** Para búsquedas de texto completo y criterios complejos (word segmentation, inverted indexes).

Solución 3 - Data Warehouse Convergente (DWS)

- **Arquitectura Shared-Nothing:** Cada unidad de procesamiento tiene su propio CPU, memoria y disco, comunicándose vía protocolos.
- **Mecanismos de Distribución:**
  - **Hash Distribution:** Distribuye datos basados en una clave para mejorar el paralelismo.
  - **Replication:** Copia tablas pequeñas en todos los nodos para evitar "joins" costosos en la red.
- **Mecanismo TOAST:** Técnica para comprimir o dividir valores de campos grandes (>2 KB) en múltiples filas físicas.

Guía de Desarrollo
El Proceso de Aplicación

1. **Presentación de Requerimientos:** Negociación multi-departamental y análisis de viabilidad.
2. **Análisis de Requerimientos:** Encuestas de mercado y técnicas.
3. **Selección de Tecnología:** Creación de diagramas de flujo de datos (DFD).
4. **Análisis de Indicadores:** Conversión de necesidades de negocio en métricas técnicas.
5. **Interacción y Análisis:** Limpieza de datos, almacenamiento intermedio e implementación de código.

Mejores Prácticas - Capas de Datos

Ventajas de la Estratificación (Layering):

- **Simplificación:** Divide tareas complejas en pasos manejables, facilitando la localización de fallos.
- **Reducción de I+D repetitivo:** Estandarizar capas permite reutilizar resultados de cálculos previos.
- **Aislamiento de datos:** Desacopla los datos sensibles o crudos de los datos estadísticos finales.

Conclusiones

- **Convergencia Tecnológica:** El Big Data ha evolucionado de simples archivos distribuidos (GFS) a ecosistemas complejos capaces de procesar flujos en milisegundos (Flink).
- **Adaptabilidad por Escenario:** No existe una herramienta única; la elección entre HBase, DWS o Spark depende estrictamente de la latencia y la complejidad de la consulta requerida.
- **Estandarización del Desarrollo:** El éxito de un proyecto de Big Data no depende solo de la tecnología, sino de un proceso riguroso que incluye análisis de indicadores y capas de datos bien definidas.
- **Escalabilidad:** Las arquitecturas *Shared-nothing* son la base de la expansión horizontal necesaria para manejar el crecimiento explosivo de datos corporativos.