Material de estudio semanal
CIB12 - Aprendizaje de Máquina y Minería de Datos
Semana 4: Desarrollo de Aplicaciones Big Data
Fuente trabajada: Huawei (2022), Capítulo 1

2. Resumen de la semana

Esta semana se estudia la parte del capítulo 1 enfocada en el **desarrollo de aplicaciones Big Data**. El contenido resalta que una buena aplicación no depende solo de programar, sino de combinar **base técnica** y **comprensión del servicio o negocio**.

El material presenta dos ejes principales:

- **Habilidades requeridas**: programación en Java y Scala, manejo de SQL y operaciones en Linux, junto con comprensión del proceso de desarrollo y del contexto del servicio.
- **Proceso general de desarrollo**: desde la formulación del requerimiento hasta la visualización final de resultados.

La idea más importante es que el desarrollo de una aplicación Big Data sigue una **secuencia ordenada de etapas**: se identifican necesidades, se analizan requerimientos, se selecciona la tecnología, se valida su viabilidad, se preparan y procesan los datos, se almacenan los resultados y luego se muestran para uso operativo.

3. Conceptos clave

4. Desarrollo del tema

Idea central
Una aplicación Big Data de calidad surge cuando se unen dos dimensiones: capacidades técnicas de desarrollo y comprensión del servicio que se desea resolver. A partir de esa base, el trabajo se organiza en un proceso secuencial que transforma una necesidad en resultados utilizables.

4.1. ¿Qué hace posible una buena aplicación Big Data?

El material responde esta pregunta a partir de dos grupos de habilidades:

1. **Fundamentos de programación**
   - Capacidad de programar con **Java** y **Scala**.
   - Familiaridad con **SQL**.
   - Manejo de **operaciones en Linux**.
2. **Experiencia en desarrollo de servicios**
   - Comprensión de los **procesos de desarrollo**.
   - Comprensión del **contexto o trasfondo del servicio**.

Esto implica que el desarrollador Big Data no solo debe saber escribir código, sino también comprender **qué problema se está resolviendo**, **cómo se integra la solución al proceso organizacional** y **cómo se traduce una necesidad del negocio en resultados útiles**.

4.2. Relación entre conocimiento técnico y conocimiento del servicio

Según el esquema del material, ambos componentes son complementarios:

- El **conocimiento técnico** permite construir la solución.
- El **conocimiento del servicio** permite orientar la solución hacia un objetivo real.

Si falta la primera parte, no se puede implementar la aplicación. Si falta la segunda, la aplicación puede funcionar técnicamente, pero no responder al problema correcto.

4.3. Desarrollo como proceso y no como acto aislado

El documento no presenta el desarrollo como una sola fase de programación, sino como un **flujo completo**. La programación aparece en la etapa de *data analysis*, pero antes de eso ya hubo trabajo de requerimientos, selección tecnológica y validación; y después de programar todavía faltan almacenamiento y presentación de resultados.

Esto enseña una idea importante para evaluación: **desarrollar una aplicación Big Data es recorrer un ciclo completo**, no solamente escribir consultas o código.

Errores comunes o confusiones frecuentes

- Creer que desarrollar una aplicación Big Data es solamente programar.
- Pensar que la selección tecnológica debe hacerse usando la tecnología más nueva sin evaluar estabilidad o viabilidad.
- Omitir el análisis de requerimientos y pasar directamente a la implementación.
- Confundir requerimientos del negocio con indicadores medibles.
- Olvidar que los resultados deben almacenarse y mostrarse para su uso operativo.

4.4. Qué enfatiza realmente esta sección

Esta parte del capítulo es **breve y orientada al proceso**. No entra en detalles extensos de algoritmos ni de implementación de código. Su foco está en:

- las competencias mínimas del desarrollador,
- la secuencia general de desarrollo,
- y los puntos que deben cuidarse antes, durante y después del análisis de datos.

Por ello, para un cuestionario, lo más probable es que se pregunten **etapas**, **relaciones entre habilidades** y **finalidad de cada fase**.

5. Procesos, arquitectura o flujo del tema

En esta sección, el PDF enfatiza más un **flujo de desarrollo** que una arquitectura técnica detallada. El proceso general es el siguiente:

1. **Requirement submission** Se inicia con negociación entre múltiples departamentos y un análisis preliminar de factibilidad del proyecto.
2. **Requirement analysis** Se realiza levantamiento de requerimientos y estudio de mercado.
3. **Technology selection** Se define el diagrama de flujo de datos y la solución técnica.
4. **Feasibility analysis** Se construye la plataforma técnica y se hacen pruebas de factibilidad.
5. **Indicator analysis** Se convierten los requerimientos en indicadores.
6. **Data interaction** Incluye recolección de datos, limpieza, almacenamiento de datos fuente y middleware.
7. **Data analysis** Se implementa el código para procesar y analizar los datos.
8. **Result storage** Los resultados se guardan en una base de datos u otra ubicación.

Concepto	Síntesis de estudio
Desarrollo de aplicaciones Big Data	Proceso de construir soluciones sobre datos masivos, integrando habilidades técnicas y entendimiento del negocio.
Programación básica	Base técnica necesaria para desarrollar aplicaciones; incluye Java, Scala, SQL y manejo de Linux.
Experiencia en desarrollo de servicios	Conocimiento del proceso de desarrollo y del contexto del servicio o problema que se desea resolver.
Requirement submission	Etapa inicial donde se negocia entre áreas y se analiza la factibilidad del proyecto.
Requirement analysis	Recolección y estudio de requerimientos mediante levantamiento de necesidades y estudio de mercado.
Technology selection	Selección de solución técnica y elaboración del diagrama de flujo de datos.
Feasibility analysis	Construcción de la plataforma técnica y pruebas para validar que la solución puede ejecutarse.
Indicator analysis	Conversión de necesidades del negocio en indicadores medibles.
Data interaction	Recolección, limpieza, almacenamiento de datos fuente y uso de middleware.
Data analysis	Implementación del código para procesar o analizar datos.
Result storage	Almacenamiento del resultado en base de datos u otra ubicación.
Results display	Presentación del resultado para su uso por el área operativa.

9. **Results display** Los resultados se presentan para uso del área de operaciones.

5.1. Lectura del flujo como cadena lógica

Necesidad → Análisis → Selección técnica → Validación → Preparación de datos → Implementación → Almacenamiento → Visualización

5.2. Tabla resumen del proceso

6. Herramientas, algoritmos o componentes importantes

Aunque esta sección no desarrolla algoritmos específicos, sí menciona componentes y habilidades importantes para el desarrollo de aplicaciones Big Data.

6.1. Lo que conviene recordar

- En esta sección, **Java, Scala, SQL y Linux** aparecen como base de competencias.
- El contenido **no se centra en algoritmos concretos**, sino en el proceso de desarrollo.
- El **diagrama de flujo de datos** y la **plataforma técnica** son piezas clave de diseño y validación.

7. Aplicaciones o ejemplos

El material de esta parte no desarrolla un caso completo de implementación, pero sí permite reconstruir aplicaciones y usos probables del proceso.

7.1. Ejemplo general de aplicación

Una organización detecta una necesidad y presenta un requerimiento. Luego:

- varias áreas negocian la viabilidad del proyecto,
- se analiza la necesidad y el mercado,
- se selecciona una tecnología adecuada,
- se construye la plataforma y se prueba,
- se recolectan y limpian los datos,
- se implementa el análisis,
- los resultados se guardan,
- y finalmente se muestran al área operativa.

Este ejemplo refleja exactamente la lógica del flujo presentado en el documento.

7.2. Relación con aplicaciones Big Data del capítulo

Dentro del mismo capítulo, Big Data aparece aplicado en dominios como:

- **Finanzas**: transacciones de alta frecuencia y análisis de riesgo crediticio.
- **Logística**: logística inteligente, control de costos y gestión de riesgos.
- **Salud**: predicción de epidemias y gestión sanitaria inteligente.
- **Internet**: perfiles de usuario, recomendación personalizada y publicidad.
- **Ciudad**: transporte inteligente y planificación urbana.

Estos ejemplos ayudan a entender que el proceso de desarrollo estudiado no se limita a un sector, sino que puede aplicarse en múltiples escenarios.

7.3. Precisión importante

El PDF no detalla aquí un ejemplo de código ni una arquitectura de despliegue completa para esta sección específica. Por eso, el estudio debe concentrarse en **la lógica del desarrollo**, **las etapas** y **las competencias requeridas**.

8. Resumen para memorizar

- Una buena aplicación Big Data requiere **habilidades técnicas** y **comprensión del servicio**.
- Las bases técnicas mencionadas son **Java, Scala, SQL y Linux**.
- También se necesita entender **el proceso de desarrollo** y **el contexto del negocio**.
- El desarrollo sigue una secuencia:

  requerimiento → análisis → selección tecnológica → factibilidad → indicadores → interacción de datos → análisis → almacenamiento → visualización

- **Technology selection** incluye el **diagrama de flujo de datos** y la **solución técnica**.
- **Feasibility analysis** consiste en construir la plataforma técnica y validar su funcionamiento.
- **Data interaction** incluye **recolección, limpieza, almacenamiento fuente y middleware**.
- **Data analysis** corresponde a la **implementación del código**.

Etapa	Propósito	Elemento clave mencionado en el PDF
Requirement submission	Acordar el inicio del proyecto	Negociación interdepartamental y factibilidad
Requirement analysis	Entender la necesidad	Encuesta de requerimientos y estudio de mercado
Technology selection	Definir cómo se hará	Diagrama de flujo de datos y solución técnica
Feasibility analysis	Verificar si es viable	Construcción de plataforma y pruebas
Indicator analysis	Traducir la necesidad a métricas	Conversión entre requerimientos e indicadores
Data interaction	Preparar el insumo de datos	Recolección, limpieza, almacenamiento fuente y middleware
Data analysis	Ejecutar la lógica de análisis	Implementación de código
Result storage	Conservar resultados	Base de datos u otra ubicación
Results display	Entregar valor al usuario final	Uso por el área operativa

Herramienta o componente	¿Qué es o qué representa?	¿Para qué sirve dentro del tema?
Java	Lenguaje de programación	Base para implementar aplicaciones Big Data
Scala	Lenguaje de programación	Base técnica importante para desarrollar soluciones
SQL	Lenguaje de consulta	Permite trabajar con datos de forma estructurada
Linux	Entorno operativo	Soporta la operación técnica del desarrollo
Diagrama de flujo de datos	Representación del movimiento de los datos	Ayuda en la selección tecnológica y diseño de la solución
Plataforma técnica	Entorno construido para el proyecto	Permite probar factibilidad antes de producción
Middleware	Capa intermedia del sistema	Participa en la interacción y manejo de datos
Base de datos u otra ubicación	Destino del resultado	Permite persistir la salida del análisis

- **Result storage** guarda la salida en base de datos u otra ubicación.
- **Results display** entrega el resultado al área operativa.
- No siempre debe elegirse la tecnología más nueva; primero debe evaluarse su **viabilidad y estabilidad**.

9. Preguntas probables de cuestionario

1. **¿Qué dos grupos de capacidades hacen posible una excelente aplicación Big Data?**
   Respuesta corta: fundamentos de programación y experiencia en desarrollo de servicios.
2. **¿Qué lenguajes de programación menciona el material como base?**
   Respuesta corta: Java y Scala.
3. **¿Qué lenguaje de consulta debe conocer el desarrollador?**
   Respuesta corta: SQL.
4. **¿Qué entorno operativo se menciona como conocimiento necesario?**
   Respuesta corta: operaciones en Linux.
5. **¿Qué incluye la etapa de *requirement submission*?**
   Respuesta corta: negociación entre múltiples departamentos y análisis de factibilidad del proyecto.
6. **¿Qué actividades forman parte de *requirement analysis*?**
   Respuesta corta: levantamiento de requerimientos y estudio de mercado.
7. **¿Qué se define en la etapa de *technology selection*?**
   Respuesta corta: el diagrama de flujo de datos y la solución técnica.
8. **¿Para qué sirve *feasibility analysis*?**
   Respuesta corta: para construir la plataforma técnica y probar si la solución es viable.
9. **¿Qué significa *indicator analysis*?**
   Respuesta corta: convertir los requerimientos en indicadores.
10. **¿Qué tareas incluye *data interaction*?**
    Respuesta corta: recolección de datos, limpieza, almacenamiento de datos fuente y middleware.
11. **¿Qué ocurre en *data analysis*?**
    Respuesta corta: se implementa el código para analizar o procesar los datos.
12. **¿Dónde se guardan los resultados del análisis?**
    Respuesta corta: en una base de datos u otra ubicación.
13. **¿Quién usa la salida de la etapa *results display*?**
    Respuesta corta: el área de operaciones.
14. **¿Es correcto elegir siempre la tecnología más nueva sin considerar estabilidad?**
    Respuesta corta: no; la selección debe considerar viabilidad y estabilidad.
15. **¿Puede usarse un host en la nube o una máquina física como servidor?**
    Respuesta corta: sí, el material lo deja como posibilidad en la evaluación tipo cuestionario.

10. Mini glosario

Big Data Application Development
Desarrollo de aplicaciones orientadas al manejo y aprovechamiento de grandes volúmenes de datos.

Programming Basics
Conocimientos técnicos base requeridos para implementar la solución.

Service Development Experience
Comprensión del proceso de desarrollo y del contexto del servicio.

Requirement Submission
Presentación inicial del requerimiento con negociación y revisión preliminar de factibilidad.

Requirement Analysis
Estudio detallado de necesidades y del entorno o mercado.

Technology Selection
Elección de la solución técnica adecuada y definición del flujo de datos.

Feasibility Analysis
Validación práctica de que la solución puede construirse y funcionar.

Indicator Analysis
Traducción de necesidades del negocio a indicadores observables o medibles.

Data Interaction
Manejo inicial de los datos: recolectar, limpiar, almacenar y conectar componentes intermedios.

Data Analysis
Etapa en la que se implementa la lógica analítica mediante código.

Result Storage
Persistencia de los resultados obtenidos.

Results Display
Presentación final de los resultados para su uso operativo.

Middleware
Componente intermedio que apoya la interacción y circulación de datos entre partes del sistema.