Machine Learning y Comunicaciones Opticas

Mg. Ing. Yury Tello Canchapoma

De la mitigación de ruido al aprendizaje de extremo a extremo:
Un mapa conceptual de ML y DL aplicado a redes ópticas.

El Límite Tradicional

Procesamiento estático de señales (DSP).

Modelos matemáticos rígidos.

Alta intervención humana requerida.

La Crisis de Complejidad

Intervención de la IA

Saturación humana

Transceptores multicanal ultra complejos.

Distorsión dinámica no lineal.

Autoconfiguración necesaria para petabytes.

La Solución: Algoritmos que no solo procesan datos, sino que aprenden de la luz.

NotebookLM

Agenda

- **Introducción:** El rol de la IA en la evolución de las comunicaciones ópticas.
- **Fundamentos Tecnológicos:** Clasificación de algoritmos de Machine Learning (ML) y Deep Learning (DL).
- **Comunicaciones por Fibra Óptica (OFC):** Mitigación de no linealidades y procesamiento de señales.
- **Comunicaciones Ópticas Inalámbricas (OWC):** Aplicaciones en FSO, VLC y entornos submarinos.
- **Redes de Comunicación Óptica (OCN):** Optimización de tráfico, monitoreo y gestión de recursos.
- **Desafíos e Implementación:** Barreras técnicas, datos y complejidad computacional.
- **Futuro y Conclusiones:** Redes informadas por la física y visión general del estudio.

Introducción a la Inteligencia Artificial en Comunicaciones Ópticas

- La creciente complejidad de los sistemas y redes de comunicación óptica requiere metodologías avanzadas para extraer información valiosa de conjuntos de datos vastos y heterogéneos.
- El aprendizaje automático (ML) y el aprendizaje profundo (DL) han surgido como herramientas fundamentales, revolucionando el análisis de datos y permitiendo la autoconfiguración automatizada.
- La adopción de estas técnicas está impulsada por la complejidad de áreas como los transceptores coherentes, el procesamiento digital avanzado de señales y la compensación de no linealidades.
- La Inteligencia Artificial (IA) ofrece soluciones innovadoras para hacer frente a la creciente complejidad computacional de los sistemas de comunicación modernos.

Clasificación del Aprendizaje Automático (ML)

Los algoritmos de ML utilizados en la comunicación óptica se clasifican generalmente en tres grandes categorías.

- **Aprendizaje Supervisado (SL):** Aprende de datos etiquetados para realizar clasificaciones y predicciones, incluyendo técnicas como Máquinas de Vectores de Soporte (SVM) y Redes Neuronales Artificiales (ANN).
- **Aprendizaje No Supervisado (USL):** Analiza datos sin etiquetar para identificar patrones, utilizando algoritmos como agrupamiento jerárquico, K-means y Análisis de Componentes Principales (PCA).
- **Aprendizaje por Refuerzo (RL):** Interactúa con un entorno determinado para aprender estrategias óptimas de toma de decisiones.

Aprendizaje Profundo (DL) en Redes Ópticas

El aprendizaje profundo (DL) utiliza redes neuronales con múltiples capas para extraer patrones complejos a partir de grandes conjuntos de datos.

- **Redes Neuronales Profundas (DNN):** Emplean múltiples capas para analizar relaciones complejas entre datos, útiles para la modelización de moduladores ópticos.
- **Redes Neuronales Recurrentes (RNN):** Diseñadas para manejar datos secuenciales, siendo especialmente útiles para el procesamiento de señales ópticas y la predicción de tráfico en redes dinámicas.
- **Redes Neuronales Convolucionales (CNN):** Sobresalen en el procesamiento de datos espaciales, como el análisis de imágenes de canales ópticos o topologías de red.
- **Aprendizaje por Refuerzo Profundo (DRL):** Combina RL y DL para facilitar la toma de decisiones inteligente en entornos ópticos altamente complejos y dinámicos.

Fibra Óptica (OFC)
Soluciones con Machine Learning

- Las SVM proporcionan soluciones eficientes para mitigar impedimentos como el ruido de fase no lineal, asegurando la integridad de la señal en sistemas de fibra.
- En el diagnóstico de fallas, las SVM transforman las tareas de clasificación en problemas de optimización no lineal, logrando una localización precisa de los errores.
- Las Redes Neuronales Artificiales (ANN) mejoran significativamente el factor Q al compensar las distorsiones no lineales de la fibra, superando a los métodos tradicionales basados en Volterra.
- Los algoritmos K-Nearest Neighbors (kNN) son altamente efectivos para detectar y mitigar impedimentos asociados al ruido en la transmisión a alta velocidad.

Fibra Óptica (OFC)
Avances en Deep Learning

- Las DNN son expertas en compensar impedimentos de fibra tanto lineales como no lineales, tareas que suelen ser un gran desafío para los métodos convencionales.
- Un desarrollo notable en la aplicación de las DNN es el entrenamiento "extremo a extremo" de los componentes del transmisor y receptor para optimizar el diseño general del sistema.
- Las arquitecturas de Redes Neuronales Recurrentes (RNN) pueden reducir la complejidad computacional en un 50% al capturar las correlaciones temporales de las señales.
- Las CNN se utilizan con gran eficacia en comunicaciones de momento angular orbital (OAM) para predecir coeficientes de modo y compensar distorsiones en sistemas de larga distancia.

Comunicaciones Inalámbricas (OWC)
Retos y Soluciones

- En los sistemas ópticos de espacio libre (FSO) y comunicación de luz visible (VLC), el ML aborda impedimentos como la turbulencia atmosférica y la interferencia lumínica.
- Las ANN se han empleado para la corrección adaptativa de frentes de onda en FSO, aumentando drásticamente la tasa de energía acoplada con menor complejidad computacional.
- El método kNN es particularmente efectivo y eficiente en sistemas de posicionamiento en interiores basados en VLC, alcanzando precisiones de hasta 2.7 cm.
- El algoritmo Expectation Maximization (EM) reduce significativamente la tasa de errores de bits (BER) y acelera la estimación de canales en sistemas FSO frente a las técnicas convencionales.

Comunicaciones Inalámbricas (OWC)
Rol del Deep Learning

- En los sistemas VLC submarinos, las DNN han demostrado ser muy eficaces para compensar distorsiones de señal severas y mejorar las tasas de transferencia de datos.
- Las redes LSTM (un tipo de RNN) mitigan con éxito los problemas de interferencia entre símbolos y el efecto de parpadeo ("flicker") en comunicaciones VLC.
- Las CNN logran una alta precisión de demodulación bajo condiciones severas de turbulencia en comunicaciones de espacio libre (FSO).
- El Aprendizaje por Refuerzo Profundo (DRL) mejora la asignación de energía dinámica y la selección de enlaces híbridos FSO/RF bajo condiciones climáticas variables.

Redes Ópticas (OCN)
Optimización mediante Machine Learning

- Las SVM se utilizan para estimar la calidad de transmisión (QoT) con una asombrosa precisión del 99.95%, reduciendo el tiempo de procesamiento en un 90% en redes de transporte.
- Las ANN son vitales para la monitorización del rendimiento óptico (OPM), identificando parámetros críticos de manera rápida y sin necesidad de recuperar el reloj.
- El Bosque Aleatorio (Random Forest) identifica formatos de modulación con un 100% de precisión y monitorea la señal a ruido, siendo altamente eficiente para entornos en tiempo real.
- El algoritmo K-means se emplea en redes ópticas pasivas para optimizar el despliegue de infraestructura, lo que reduce el coste de instalación hasta en un 50%.

Redes Ópticas (OCN)
Monitoreo Avanzado con Deep Learning

- Las redes LSTM han reducido el error en el monitoreo de la Relación Señal a Ruido (OSNR) en un 72% y acelerado el tiempo de respuesta a 0.2 ms.
- Las DNN logran optimizar la Asignación de Rutas y Espectro (RSA) en Redes Ópticas Elásticas (EONs), disminuyendo la fragmentación de espectro y la latencia del sistema.
- Mediante el análisis de diagramas de constelación, las CNN pueden medir distorsiones complejas y estimar métricas de red en menos de medio segundo.
- El DRL optimiza las políticas de enrutamiento y asignación de longitudes de onda interactuando dinámicamente con el entorno de red en sistemas híbridos.

Desafíos Actuales de Implementación

- **Gestión de Datos:** Existe una enorme dificultad para obtener grandes cantidades de datos etiquetados bajo diversas condiciones operativas, lo que a menudo provoca sobreajuste en los modelos.
- **Problemas de Interpretabilidad:** Es un gran desafío comprender la lógica interna detrás de las decisiones generadas por los modelos opacos de DL (como las DNN).
- **Requisitos Computacionales:** El entrenamiento y despliegue en tiempo real de redes neuronales profundas demanda grandes infraestructuras informáticas, lo que limita su viabilidad en escenarios inmediatos.
- **Problemas de Escalabilidad:** Integrar algoritmos avanzados de inteligencia artificial dentro de arquitecturas tradicionales de comunicación óptica requiere rediseños y modificaciones complejas de hardware.

Direcciones Futuras

- **Redes Informadas por la Física (PINNs):** Se prevé la integración del conocimiento de la física óptica dentro del Machine Learning para operar con éxito en entornos donde los datos son escasos.
- **Optimización Dinámica y Aprendizaje Híbrido:** Aplicar Aprendizaje por Refuerzo (RL) ininterrumpido para autoajustar parámetros de red, combinando algoritmos convencionales con DL para reducir el impacto computacional.
- **Aprendizaje "End-to-End":** El enfoque del futuro recae en optimizar conjuntamente la línea de comunicación completa, desde la codificación inicial hasta la recuperación final del receptor.

Conclusiones

- Se ha demostrado cómo estas tecnologías abordan los desafíos únicos de cada dominio, impactando de manera efectiva en la optimización del sistema y en la mejora del rendimiento.
- Además de destacar las mejoras cuantitativas, el análisis ofrece comparaciones cualitativas que ilustran cómo los diferentes algoritmos mejoran el rendimiento del sistema de manera única.
- A pesar de los retos actuales para su implementación, la investigación identifica soluciones potenciales y direcciones futuras, empoderando a investigadores y profesionales para tomar decisiones informadas sobre las mejores herramientas para sus redes.