Informe de Laboratorio
CIB12 - Aprendizaje de Maquina y Mineria de Datos

Curso: CIB12
Departamento: Telecomunicaciones
Docente: TELLO CANCHAPOMA, YURY OSCAR
Alumno: Guevara Lázaro Jhunior Eduardo

24 de marzo de 2026

1. 4. Procedimiento

1.1. Etapa 1. Generación inicial de prompts en 10 LLM

En esta primera etapa se diseñó un prompt amplio y genérico, de acuerdo con la consigna del laboratorio, con el propósito de observar el comportamiento inicial de distintos modelos de lenguaje sin imponer restricciones de rol, formato, número de elementos o exigencias explícitas de verificación. El prompt utilizado fue el siguiente:

> *"Explícame cómo se diseña y desarrolla un proyecto completo de ingeniería electrónica basado en un ESP32 que incluya el diseño de una PCB y una aplicación móvil para interactuar con el sistema. Describe las etapas del desarrollo, los componentes electrónicos que suelen emplearse, las decisiones importantes de diseño, los protocolos de comunicación que pueden usarse, las consideraciones de alimentación y protección, las pruebas necesarias y los problemas más comunes que pueden aparecer tanto en el hardware como en el firmware y la app."*

Posteriormente, el prompt fue ejecutado en los modelos DeepSeek, Qwen, Gemini, Mistral, Perplexity, Ernie Bot, ChatGPT Free y ChatGPT Plus. Aunque la guía solicita al menos 10 LLM, en la presente entrega se cuenta con 8 salidas efectivamente registradas, por lo que esta diferencia se reconoce como una limitación metodológica del ejercicio.

A partir de las respuestas obtenidas, se elaboró una tabla comparativa para registrar el enfoque general de cada modelo, así como los posibles fragmentos sospechosos de alucinación. En esta etapa, la clasificación realizada es preliminar, ya que la confirmación formal corresponde a la Etapa 3 mediante verificación en bases de datos indexadas y fuentes técnicas especializadas.

LLM	**Síntesis de la respuesta**	**Fragmentos sospechosos subrayados**	**Tipo preliminar**
DeepSeek	Respuesta muy estructurada, con tablas, valores técnicos concretos, recomendaciones de diseño eléctrico, protección, pruebas y mitigación de fallos.	"Caída de tensión $\geq$ 1,2 V a 1 A", "Reconexión en $<$ 30 s", "Capacitor de 470μF–1000μF"	Factual
Qwen	Respuesta ordenada en fases secuenciales, con fuerte orientación a arquitectura del sistema, alimentación, protocolos y producción/despliegue.	"El ESP32 consume picos de $\sim$ 500 mA al transmitir", "ESP-IDF incorpora FreeRTOS obligatoriamente"	Factual / Lógica

LLM	Síntesis de la respuesta	Fragmentos sospechosos subrayados	Tipo preliminar
Gemini	Respuesta técnica y detallada, con énfasis en integración vertical, decisiones de plataforma, consumo, RF y pruebas extremo a extremo.	"Picos de hasta 500 mA durante la transmisión Wi-Fi", "Separación de tierra analógica y digital"	Factual / Lógica
Mistral	Respuesta clara y bien segmentada, orientada a flujo de desarrollo, selección de componentes, protocolos y validación del sistema integrado.	"ESP32-WROOM-32 (WiFi/Bluetooth clásico)", "Estrés térmico de −20°C a 85°C"	Factual
Perplexity	Respuesta comparativa y bastante sintética, con énfasis en arquitectura, PCB, protocolos y relación entre hardware, firmware y app.	"No exceder ∼ 12–40 mA por pin", "Protección con Zener o TVS en líneas de alimentación y sensores"	Factual
Ernie Bot	Respuesta generalista y ordenada por etapas, componentes, protocolos, pruebas y conclusiones, con menor profundidad técnica que otros modelos.	"Antena cerámica para mejorar la comunicación Wi-Fi/Bluetooth", "Sobrecalentamiento de componentes, especialmente el ESP32"	Factual / Lingüística
ChatGPT Free	Respuesta estructurada y realista, con separación entre hardware, firmware y app, además de riesgos de integración y pruebas necesarias.	"Cristal de 40 MHz requerido para operación estable", "Consumo pico hasta ∼ 500 mA en Wi-Fi", "Prueba de interferencia EMI"	Factual
ChatGPT Plus	Respuesta balanceada y más cautelosa, con integración sistémica entre hardware, firmware y aplicación, y mejor manejo de incertidumbre.	"OTA exige particionado y recuperación robusta", "La antena debe respetar zona libre de cobre", "Wi-Fi/BLE generan picos superiores al consumo medio"	Factual

Cuadro 1: Tabla comparativa de respuestas iniciales y fragmentos sospechosos de alucinación.

De manera general, se observó que todos los modelos respondieron dentro del tema solicitado, por lo que no se identificaron alucinaciones de contexto evidentes. Asimismo, en esta primera etapa no aparecieron citas académicas, DOI ni referencias bibliográficas específicas, por lo que tampoco se detectaron alucinaciones de referencia en sentido estricto. Sin embargo, sí se encontraron numerosos fragmentos con valores numéricos, afirmaciones técnicas específicas y generalizaciones de diseño que requieren verificación posterior.

En consecuencia, las posibles alucinaciones detectadas en esta etapa se concentraron principalmente en la categoría de **alucinaciones factuales**, debido al uso de cifras, parámetros o recomendaciones técnicas presentadas como válidas sin respaldo visible. En menor medida, también se identificaron posibles **alucinaciones lógicas**, especialmente cuando algunos modelos generalizaron decisiones de ingeniería como si fueran universalmente aplicables, y **alucinaciones lingüísticas o estilísticas**, en aquellos casos donde la redacción fue correcta en la forma, pero demasiado amplia o poco verificable en su contenido.

Como cierre de esta etapa, puede afirmarse que el prompt genérico permitió obtener respuestas útiles para una comparación inicial, pero también evidenció que, ante instrucciones amplias y abiertas, varios modelos tienden a introducir datos técnicos específicos sin aclarar su nivel de certeza. Esto justifica la necesidad de rediseñar el prompt en la siguiente etapa mediante estrategias de contextualización, especificidad, formato esperado y verificación explícita.

1.2. Etapa 2. Aplicación de ingeniería de prompts

En esta segunda etapa se rediseñó el prompt inicial aplicando estrategias de ingeniería de prompts orientadas a reducir ambigüedad, mejorar la estructura de salida y disminuir la probabilidad de alucinaciones. Siguiendo la guía del laboratorio, el nuevo diseño incorporó cuatro estrategias

principales: **contextualización**, al asignar un rol experto al modelo; **especificidad**, al exigir cantidades exactas de elementos a incluir; **formato esperado**, al imponer una estructura obligatoria basada en tablas y listas; y **verificación explícita**, al pedir que el modelo indicara su nivel de certeza y evitara presentar datos dudosos como hechos confirmados.

El prompt optimizado utilizado fue el siguiente:

> *"Eres un ingeniero electrónico especializado en sistemas embebidos, diseño de PCB y desarrollo de aplicaciones móviles para dispositivos IoT. Explica cómo se diseña y desarrolla un proyecto completo basado en un ESP32 que incluya una PCB y una aplicación móvil para interactuar con el sistema.*
>
> *Tu respuesta debe cumplir estas condiciones:*
>
> - *Incluye exactamente 8 etapas del desarrollo.*
> - *Incluye exactamente 10 componentes electrónicos comunes y explica para qué sirve cada uno.*
> - *Incluye exactamente 6 decisiones importantes de diseño.*
> - *Incluye exactamente 5 protocolos de comunicación que podrían usarse entre el ESP32, periféricos, la app móvil o la nube.*
> - *Incluye exactamente 5 consideraciones de alimentación y protección.*
> - *Incluye exactamente 6 pruebas necesarias para validar el sistema.*
> - *Incluye exactamente 6 problemas comunes, distribuidos entre hardware, firmware y app móvil.*
>
> *Formato de salida obligatorio:*
>
> 1. *Introducción breve.*
> 2. *Tabla de etapas del desarrollo.*
> 3. *Tabla de componentes electrónicos y función.*
> 4. *Lista numerada de decisiones de diseño.*
> 5. *Tabla de protocolos de comunicación, caso de uso y ventaja.*
> 6. *Lista de consideraciones de alimentación y protección.*
> 7. *Lista de pruebas necesarias.*
> 8. *Lista de problemas comunes, separando hardware, firmware y aplicación móvil.*
> 9. *Conclusión breve.*
>
> *Verificación explícita:*
>
> - *No inventes referencias, autores, normas, DOI ni valores numéricos específicos si no estás seguro.*
> - *Si mencionas un dato técnico específico, una norma o una referencia, indica al final entre paréntesis una de estas etiquetas: [seguro], [probable] o [no verificado].*
> - *Si no estás seguro de un dato, dilo explícitamente.*
> - *No presentes información dudosa como si fuera un hecho confirmado."*

Una vez rediseñado el prompt, este se ejecutó nuevamente en el mismo conjunto de modelos utilizados en la etapa anterior. En la presente evidencia quedaron registradas respuestas optimizadas de DeepSeek, Qwen, Gemini, Mistral, Perplexity, Ernie Bot y las variantes de ChatGPT empleadas en el experimento. Aunque la guía plantea idealmente trabajar con diez modelos, en esta entrega se dispone de ocho ejecuciones documentadas, lo que se declara como limitación metodológica.

Los resultados mostraron un cambio claro respecto de la etapa inicial. Mientras que con el prompt genérico las respuestas presentaban estructuras heterogéneas, distinto nivel de profundidad y ausencia de marcas de certeza, con el prompt optimizado casi todos los modelos produjeron respuestas más uniformes, ordenadas y fáciles de comparar. La mayoría respetó la exigencia de incluir exactamente 8 etapas, 10 componentes, 6 decisiones, 5 protocolos, 5 consideraciones de alimentación y protección, 6 pruebas y 6 problemas comunes, además de utilizar tablas o listas claramente separadas.

Asimismo, el rediseño mejoró la trazabilidad de posibles errores, ya que varios modelos comenzaron a etiquetar afirmaciones con marcas como `[seguro]`, `[probable]` o `[no verificado]`. Esto facilitó la identificación de fragmentos candidatos a verificación en la etapa siguiente, especialmente cuando aparecieron cifras concretas, recomendaciones técnicas particulares o afirmaciones normativas.

No obstante, la optimización del prompt no eliminó por completo las posibles alucinaciones. Persistieron algunos fragmentos con cifras técnicas o afirmaciones específicas que seguían requiriendo contraste documental, por ejemplo valores concretos de corriente, recomendaciones de temperatura extrema, criterios de protección o afirmaciones sobre certificaciones, protocolos y límites eléctricos. En otras palabras, la mejora en el diseño del prompt redujo principalmente la ambigüedad estructural y el desorden expositivo, pero no garantizó por sí sola la veracidad total del contenido técnico.

La comparación entre respuestas iniciales y optimizadas se resume en la Tabla 2.

Criterio	**Prompt genérico**	**Prompt optimizado**
Rol asignado al modelo	No se definió rol ni contexto profesional.	Se definió al modelo como ingeniero electrónico especializado en sistemas embebidos, PCB y apps IoT.
Nivel de especificidad	Abierto, sin cantidades exactas ni límites formales.	Se exigieron cantidades exactas de etapas, componentes, decisiones, protocolos, pruebas y problemas.
Formato de salida	Libre y variable según cada LLM.	Estructura obligatoria con tablas, listas y conclusión breve.
Control de incertidumbre	No se pidió reconocer dudas ni límites de certeza.	Se pidió etiquetar afirmaciones como `[seguro]`, `[probable]` o `[no verificado]`.
Facilidad de comparación entre modelos	Baja, por diferencias de extensión, orden y profundidad.	Alta, porque la mayoría respondió bajo una estructura semejante.
Facilidad de selección de claims para BDI	Media, porque había que extraer afirmaciones de textos muy heterogéneos.	Alta, debido a la presencia de etiquetas de certeza y mayor segmentación temática.
Tipo de problemas predominantes	Heterogeneidad, afirmaciones abiertas, datos técnicos sin contexto y respuestas menos auditables.	Persistencia de algunos datos técnicos discutibles, pero con menor ambigüedad formal y mayor facilidad de verificación.

Cuadro 2: Comparación entre las respuestas obtenidas con prompt genérico y prompt optimizado.

A nivel cualitativo, se observó que las respuestas optimizadas fueron superiores en tres dimensiones. En primer lugar, presentaron **mayor claridad estructural**, ya que separaron explícitamente hardware, firmware, aplicación móvil, protocolos y pruebas. En segundo lugar, ofrecieron **mayor completitud controlada**, pues tendieron a cubrir todos los bloques exigidos por la

consigna. En tercer lugar, lograron **mejor verificabilidad**, ya que las afirmaciones técnicas quedaron más visibles y delimitadas para su posterior contraste en una Base de Datos Indexada.

En síntesis, la aplicación de ingeniería de prompts permitió transformar una consulta abierta en una instrucción técnica reproducible y comparable. La estrategia más efectiva fue la combinación de rol experto, cantidades exactas, formato obligatorio y declaración explícita de incertidumbre. Gracias a ello, las respuestas mejoradas resultaron más útiles para fines académicos, más fáciles de auditar y más adecuadas para la verificación documental desarrollada en la etapa siguiente.

1.3. Etapa 3. Verificación académica en BDI

En esta etapa se seleccionaron dos afirmaciones por cada modelo de lenguaje evaluado, priorizando aquellas que incluían valores técnicos, restricciones de diseño, protocolos, requisitos de hardware o afirmaciones presentadas con alto nivel de certeza. Dado que el tema del laboratorio se centra en diseño electrónico con ESP32, PCB y aplicación móvil, varias afirmaciones no remitían directamente a artículos científicos, sino a especificaciones técnicas del fabricante y documentación primaria de plataforma. Por ello, la verificación se realizó principalmente contra documentación oficial y técnica especializada, dejando constancia de los casos confirmados, contradichos o inconclusos.

Asimismo, debe dejarse constancia de una limitación metodológica: aunque la guía solicita verificación sobre diez LLM, en la presente experiencia se trabajó con ocho respuestas efectivamente registradas y comparables, correspondientes a DeepSeek, Qwen, Gemini, Mistral, Perplexity, Ernie Bot, ChatGPT Free y ChatGPT Plus.

LLM	Prompt usado	Afirmación seleccionada	Tipo preliminar	Verificación	Alucinación	Fuente real
DeepSeek	Genérico	"ESP-IDF (profesional, mayor control, RTOS)"	Factual	Confirmado: ESP-IDF integra FreeRTOS como componente del framework.	No	Documentación oficial ESP-IDF / FreeRTOS
DeepSeek	Genérico	"La antena del ESP32 debe mantenerse sin plano de tierra debajo y alejada del ruido digital"	Factual	Confirmado en lo sustancial: las guías oficiales de hardware exigen keep-out, control del ruteo RF y separación respecto de señales de alta frecuencia.	No	Espressif Hardware Design Guidelines
Qwen	Genérico	"El chip suelto requiere cristal de 40 MHz"	Factual	Confirmado parcialmente: la documentación del ESP32 y del módulo WROOM indica cristal externo de 40 MHz para funcionalidad Wi-Fi/Bluetooth.	No	ESP32 Datasheet / ESP32-WROOM-32 Datasheet
Qwen	Genérico	"Android 12+ requiere permisos BLUETOOTH_SCAN y BLUETOOTH_CONNECT para BLE"	Factual	Confirmado: Android documenta esos permisos para escaneo y conexión Bluetooth en Android 12 o superior.	No	Android Developers
Gemini	Genérico	"El ESP32 opera a 3.3 V"	Factual	Confirmado: en módulos ESP32-WROOM-32 la alimentación recomendada se sitúa en el rango 3.0–3.6 V, siendo 3.3 V el valor nominal de uso.	No	ESP32-WROOM-32 Datasheet
Gemini	Genérico	"La zona de antena requiere keep-out libre de cobre"	Factual	Confirmado: las guías de diseño recomiendan un área de despeje alrededor de la antena y ausencia de cobre/ruteo en esa zona.	No	Espressif Hardware Design Guidelines
Mistral	Optimizado	"ESP32-WROOM-32E / WROOM-32 incorpora Wi-Fi y Bluetooth clásico + BLE"	Factual	Confirmado: la familia ESP32/WROOM documenta compatibilidad con Bluetooth BR/EDR y Bluetooth LE.	No	ESP32 Datasheet / ESP32-WROOM-32 Datasheet
Mistral	Optimizado	"FreeRTOS integrado en ESP-IDF"	Factual	Confirmado: la guía oficial de ESP-IDF lo declara explícitamente.	No	ESP-IDF Programming Guide
Perplexity	Optimizado	"No exceder aproximadamente 12–40 mA por GPIO"	Factual	Inconcluso: no se encontró en la documentación revisada una formulación oficial equivalente y universal en ese rango para todos los pines/módulos.	Sí, potencial	No se confirmó de forma directa
Perplexity	Optimizado	"La app puede perder el dispositivo BLE por permisos de Bluetooth no aceptados"	Factual	Confirmado parcialmente: Android exige permisos de Bluetooth/nearby devices; la pérdida de descubrimiento por permisos es técnicamente plausible.	No	Android Developers
Ernie Bot	Genérico	"Antena externa o cerámica para mejorar la comunicación"	Factual / Lingüística	Inconcluso: es una recomendación genérica válida en algunos diseños, pero no es una exigencia general del ESP32 ni quedó respaldada como regla universal.	Parcial	Soporte insuficiente como afirmación universal

LLM	Prompt usado	Afirmación seleccionada	Tipo preliminar	Verificación	Alucinación	Fuente real
Ernie Bot	Genérico	"Sobrecalentamiento de componentes, especialmente el ESP32"	Lingüística / Factual	Inconcluso: posible en ciertos escenarios, pero no aparece como condición general documentada para todo proyecto ESP32.	Parcial	No se confirmó como regla general
ChatGPT Free	Genérico	"Cristal de 40 MHz requerido para operación estable"	Factual	Confirmado en el contexto Wi-Fi/Bluetooth y del módulo WROOM-32, que integra cristal de 40 MHz.	No	ESP32 Datasheet / ESP32-WROOM-32 Datasheet
ChatGPT Free	Genérico	"Prueba de interferencia EMI/EMC"	Lingüística / Factual	Confirmado parcialmente: es una práctica técnica razonable en validación de hardware, aunque no siempre obligatoria en prototipos académicos.	No	Guías de diseño y validación de hardware
ChatGPT Plus	Optimizado	"FreeRTOS integrado [seguro]"	Factual	Confirmado: la documentación oficial lo establece de manera explícita.	No	ESP-IDF Programming Guide
ChatGPT Plus	Optimizado	"Manejo de permisos en Android [probable]"	Factual	Confirmado: la plataforma Android exige permisos específicos para Bluetooth y dispositivos cercanos en versiones modernas.	No	Android Developers

Cuadro 3: Verificación de afirmaciones seleccionadas en la Etapa 3.

A partir de la verificación realizada, se observó que la mayoría de afirmaciones relacionadas con arquitectura general, uso de ESP-IDF, Bluetooth, alimentación nominal del módulo y lineamientos de PCB sí pudieron ser confirmadas en fuentes técnicas primarias. En cambio, las afirmaciones más problemáticas fueron aquellas que introducían rangos numéricos muy concretos sin contexto suficiente, por ejemplo límites de corriente por GPIO o valores universales de diseño aplicados a todos los escenarios.

En términos de clasificación, las alucinaciones más frecuentes siguieron siendo de tipo **factual**, ya que los modelos tendieron a presentar como seguros algunos números o umbrales técnicos que no siempre aparecieron respaldados de forma directa en la documentación primaria consultada. En segundo lugar aparecieron formulaciones **lingüísticas o estilísticas**, especialmente cuando la respuesta sonaba técnica y convincente, pero en realidad expresaba recomendaciones demasiado generales, imposibles de confirmar como regla universal.

Como resultado de esta etapa, puede afirmarse que los modelos mostraron mejor desempeño cuando se limitaron a describir principios generales de diseño y peor desempeño cuando ofrecieron cifras exactas o generalizaciones fuertes sin fuente explícita. Esta observación servirá de base para el análisis comparativo de la etapa siguiente.

1.4. Etapa 4. Análisis y discusión comparativa

A partir de la comparación entre las respuestas generadas con el prompt genérico y las obtenidas con el prompt optimizado, se identificaron diferencias relevantes en tres dimensiones: cantidad y tipo de afirmaciones potencialmente alucinadas, impacto de las estrategias de ingeniería de prompts y nivel de confiabilidad académica de cada modelo.

En primer lugar, con la evidencia reunida no es metodológicamente correcto afirmar de manera absoluta que un único modelo fue el que más alucinó en todo el experimento, ya que no se realizó un conteo exhaustivo de cada fragmento sospechoso en la totalidad de respuestas. Sin embargo, sí es posible establecer tendencias comparativas a partir de los fragmentos seleccionados y de la verificación documental desarrollada en la etapa anterior.

De manera general, los modelos que más concentraron **posibles alucinaciones factuales** fueron aquellos que introdujeron cifras técnicas específicas, umbrales eléctricos o reglas de diseño muy concretas sin acompañarlas de una aclaración sobre su nivel de certeza. En esta tendencia destacaron principalmente **DeepSeek**, **Perplexity** y **ChatGPT Free**, debido a que sus respuestas incluyeron valores numéricos o afirmaciones técnicas cerradas que exigieron verificación posterior y que, en algunos casos, no pudieron confirmarse de forma directa. En particular, Perplexity resultó el caso más problemático dentro de las afirmaciones verificadas, ya que presentó como segura una cifra de corriente por GPIO que no pudo confirmarse de manera directa en la documentación técnica revisada.

Por otro lado, **Ernie Bot** mostró una tendencia distinta: más que producir errores claramente cuantificables, generó afirmaciones amplias y técnicamente plausibles, pero demasiado generales para ser confirmadas como reglas universales. Por ello, su patrón de error se asoció más con **alucinaciones lingüísticas o estilísticas** y, en menor grado, con alucinaciones factuales de baja precisión. En cambio, **Qwen**, **Gemini** y **Mistral** ofrecieron respuestas relativamente más estables, aunque también incluyeron afirmaciones específicas que requirieron validación documental.

En segundo lugar, el análisis comparativo muestra que las estrategias de ingeniería de prompts sí redujeron errores y mejoraron la utilidad académica de las respuestas. La estrategia de **contextualización** ayudó a que los modelos adoptaran una voz técnica más consistente con el área de ingeniería electrónica. La **especificidad** redujo respuestas vagas o excesivamente libres, ya que obligó a cubrir exactamente un número determinado de etapas, componentes, decisiones, protocolos, pruebas y problemas. El **formato esperado** facilitó la comparación entre modelos,

pues homogeneizó la estructura de salida mediante tablas y listas. Finalmente, la **verificación explícita** fue la estrategia más útil para el análisis posterior, ya que forzó a varios modelos a reconocer incertidumbre mediante etiquetas como `[seguro]`, `[probable]` y `[no verificado]`.

Esto significa que el prompt optimizado no eliminó completamente las alucinaciones, pero sí produjo tres mejoras claras. Primero, disminuyó la ambigüedad formal de las respuestas. Segundo, volvió más visibles los puntos técnicamente sensibles que requerían verificación. Tercero, redujo la apariencia de certeza injustificada, especialmente en los modelos que sí obedecieron la instrucción de marcar el nivel de confianza de sus afirmaciones.

En tercer lugar, respecto a la confiabilidad académica, el modelo que mostró el comportamiento más consistente fue **ChatGPT Plus**, no porque estuviera libre de posibles errores, sino porque presentó una respuesta más equilibrada, mejor estructurada y con mayor disposición a matizar afirmaciones técnicas. También **Gemini** y **Mistral** mostraron un desempeño sólido en términos de organización y pertinencia temática. En contraste, **Perplexity** destacó por una respuesta ordenada pero con al menos una afirmación técnica puntual no confirmada, mientras que **Ernie Bot** fue menos confiable para fines académicos estrictos debido a su tendencia a formular recomendaciones generales difíciles de verificar con precisión.

La Tabla 4 resume estas tendencias.

LLM	**Tendencia principal**	**Tipo de alucinación predominante**	**Valoración académica**
DeepSeek	Respuesta muy técnica, con varios valores y recomendaciones específicas	Factual	Buena, pero requiere verificación de cifras
Qwen	Respuesta estructurada y técnica, con afirmaciones concretas sobre plataforma	Factual / Lógica	Buena
Gemini	Respuesta completa, clara y relativamente estable	Factual	Muy buena
Mistral	Respuesta ordenada y consistente en el flujo de desarrollo	Factual	Muy buena
Perplexity	Respuesta sintética y clara, pero con al menos una afirmación no confirmada	Factual	Media-alta
Ernie Bot	Respuesta generalista, menos precisa y más difícil de auditar	Lingüística / Factual	Media
ChatGPT Free	Respuesta útil, pero con varias afirmaciones técnicas puntuales que exigen contraste	Factual	Buena
ChatGPT Plus	Respuesta más balanceada, estructurada y cautelosa frente a la incertidumbre	Factual, con mejor control de certeza	Muy alta

Cuadro 4: Discusión comparativa de tendencias de alucinación y confiabilidad académica.

En síntesis, el análisis comparativo permite concluir que la mayor parte de los errores observados no correspondió a invención de referencias bibliográficas, sino a **alucinaciones factuales** relacionadas con cifras, límites técnicos, recomendaciones de diseño o formulaciones excesivamente generales presentadas como hechos firmes. Asimismo, se comprobó que el diseño del prompt influye directamente en la calidad de la respuesta: cuanto más claro, específico, estructurado y explícito fue el prompt, menor fue la dispersión de resultados y mayor la posibilidad de auditoría académica.

Por tanto, la principal lección de esta etapa es que la confiabilidad de un LLM no depende única-

mente del modelo en sí, sino también del nivel de precisión con que se formule la instrucción. Un prompt bien diseñado no reemplaza la verificación documental, pero sí reduce significativamente el riesgo de error y mejora la calidad del trabajo académico.

2. 5. Resultados esperados

A partir del desarrollo del laboratorio se obtuvieron resultados consistentes con los objetivos planteados en la guía. En primer lugar, fue posible identificar y clasificar distintos tipos de alucinaciones en las respuestas generadas por los modelos evaluados. Las más frecuentes fueron las **alucinaciones factuales**, especialmente cuando los LLM introdujeron valores numéricos, límites eléctricos, recomendaciones de diseño o afirmaciones técnicas específicas sin una fuente visible que las respaldara. En menor proporción, también se observaron **alucinaciones lógicas**, cuando algunos modelos generalizaron decisiones de ingeniería como si fueran universalmente válidas, y **alucinaciones lingüísticas o estilísticas**, sobre todo en respuestas formalmente correctas pero poco verificables.

En segundo lugar, la comparación entre las respuestas iniciales y las respuestas obtenidas con el prompt optimizado mostró que la **ingeniería de prompts mejora de manera significativa la calidad de salida**. El uso de contextualización, especificidad, formato esperado y verificación explícita permitió reducir la ambigüedad, homogeneizar la estructura de las respuestas y facilitar la detección de afirmaciones críticas. Esto no eliminó completamente los errores, pero sí disminuyó la dispersión entre modelos y aumentó la posibilidad de auditoría académica.

En tercer lugar, la etapa de verificación documental confirmó que no todas las afirmaciones técnicas emitidas por los LLM podían aceptarse como válidas sin contraste externo. Varias afirmaciones generales sobre ESP32, integración con ESP-IDF, Bluetooth, requisitos de alimentación y lineamientos básicos de diseño de PCB pudieron ser confirmadas en documentación técnica primaria. Sin embargo, algunas cifras concretas o recomendaciones expresadas con exceso de seguridad no lograron confirmarse de manera directa, por lo que fueron consideradas potenciales alucinaciones o afirmaciones inconclusas. Esto demostró la importancia de complementar el uso de IA con verificación en fuentes confiables.

En cuarto lugar, el análisis comparativo permitió establecer diferencias de confiabilidad entre modelos. En términos generales, los modelos que mostraron mayor utilidad académica fueron aquellos que produjeron respuestas mejor estructuradas, más cautelosas en sus afirmaciones y más consistentes con el prompt optimizado. En contraste, los modelos que tendieron a introducir cifras técnicas muy precisas sin justificación explícita resultaron más riesgosos para tareas académicas o de apoyo al diseño.

Debe señalarse, no obstante, que existe una limitación metodológica importante en esta experiencia: aunque el laboratorio plantea idealmente la comparación de al menos diez modelos, la presente evidencia documentada se basó en ocho respuestas efectivamente registradas y comparables. Por ello, los resultados obtenidos deben interpretarse como válidos dentro del conjunto analizado, pero no como una evaluación exhaustiva del universo total de LLM disponibles.

En síntesis, los resultados del laboratorio permiten concluir que los modelos de lenguaje son herramientas útiles para generar explicaciones técnicas iniciales y organizar información compleja, pero no deben considerarse fuentes finales de verdad en contextos académicos o de ingeniería. La principal contribución de este ejercicio fue demostrar que la calidad de las respuestas depende en gran medida de cómo se formula el prompt y de si posteriormente se realiza una verificación rigurosa de las afirmaciones producidas.

2.1. Conclusiones críticas

A partir de los resultados obtenidos, se concluye que la **fiabilidad de un LLM no depende únicamente del modelo, sino también del diseño de la instrucción que recibe**. Un prompt amplio y genérico favorece respuestas más variables, menos controladas y con mayor probabilidad de incluir afirmaciones técnicas no verificadas. En cambio, un prompt optimizado, con rol definido, estructura obligatoria, nivel de detalle controlado y solicitud explícita de reconocimiento de incertidumbre, produce respuestas más comparables, auditables y útiles para el análisis académico.

Asimismo, se concluye que la **verificación documental es indispensable**. Incluso cuando una respuesta parece técnicamente correcta y está bien redactada, puede contener datos imprecisos, exageraciones o generalizaciones que solo se detectan al contrastarla con fuentes confiables. Por tanto, en contextos de investigación, docencia o desarrollo tecnológico, el uso de LLM debe entenderse como un apoyo para explorar, organizar o resumir información, pero no como sustituto de la validación técnica y bibliográfica.

Finalmente, este laboratorio demuestra que la **ingeniería de prompts constituye una competencia crítica** para el uso responsable de inteligencia artificial generativa. Saber formular instrucciones claras, específicas y verificables no solo mejora la calidad de las respuestas, sino que también reduce el riesgo de error y fortalece el valor académico del trabajo realizado.